

ChatSearch Paper Summary

اسم الورقة:

ChatSearch: a Dataset and a Generative Retrieval Model for General Conversational Image Retrieval

الفكرة العامة:

الورقة تقترح نظامًا للبحث عن الصور من خلال محادثة بين الإنسان والحاسوب. المستخدم لا يكتب فقط وصفًا مباشرًا للصورة، بل يتفاعل مع النظام عبر نصوص وصور وعدة جولات حوارية، والنظام يحاول فهم النية المخفية واسترجاع الصورة المناسبة.

المشكلة التي تعالجها الورقة

معظم أنظمة Image Retrieval تعتمد على:

- نص مباشر
- صورة مرجعية
- وصف بسيط

لكنها ضعيفة عندما يكون البحث على شكل محادثة متعددة الجولات وفيها نص وصور معًا.

الحل المقترح

الورقة قدمت شيئين:

- Dataset اسمها ChatSearch تحتوي محادثات نصية وبصرية متعددة الجولات للبحث عن الصور.
- Model اسمه ChatSearcher نموذج Generative Retrieval يستطيع:
 1. فهم النص والصورة معًا
 2. استنتاج نية المستخدم
 3. توليد رد نصي
 4. أو استرجاع صورة مناسبة

أنواع البيانات داخل ChatSearch

النوع	المدخلات	الهدف
tChatSearch	محادثة نصية فقط	استرجاع صورة
iChatSearch	صورة + تعليمات نصية	استرجاع صورة
mChatSearch	محادثة متعددة الجولات نص + صور	استرجاع صورة

معمارية ChatSearcher

النموذج يعتمد على:

- LLM / Vicuna-7B لفهم الحوار
- CLIP Vision Encoder لاستخراج خصائص الصور
- Q-Former لضغط خصائص الصورة
- [IMG] token لتحديد متى يجب استرجاع صورة
- Feature Queue لتخزين عينات صور كثيرة تساعد في تحسين الاسترجاع

التدريب

التدريب يتم على مرحلتين :

- Stage 1: Image-Text Alignment

تعليم النموذج الربط بين الصورة والنص.

- Stage 2: Conversational Instruction Tuning

تعليم النموذج التعامل مع محادثات وتعليمات متعددة الوسائط

النتائج

النموذج ChatSearcher تفوق على :

- CLIP
- FROMAGE

خصوصاً في مهمة mChatSearch وهذا يثبت أهمية استخدام السياق التاريخي في المحادثة وليس الاعتماد على جملة واحدة فقط.

الـ Gap المستفادة من الورقة

هذه الورقة قوية في دمج النص + الصورة داخل محادثة لكنها لا تغطي باقي الوسائط مثل:

- الصوت
- تعبيرات الوجه
- الحركة
- اللمس
- المؤشرات الفسيولوجية
- المستشعرات البيئية

إنّ نستفيد منها كنقطة أساس لكن مشروعنا يوسّع الفكرة نحو Multimodal CIR أوسع والـ prototype سيركز على الصوت + تعبيرات الوجه

Figure 1

اسم الصورة عندي :

ChatSearch_Figure1_General_Conversational_Image_Retrieval

ChatSearcher يشرح فكرة العامة للـ

النظام يقبل مدخلات متعددة الوسائط ويولد نص أو يسترجع صور



Figure 2 — مهم

اسم صورة عندي :

ChatSearch_Figure2_Data_Construction_Pipeline

لأنه يوضح Pipeline بناء Dataset.




Figure 3 — مهم

لأنه يوضح بناء الحوار متعدد الوسائط.

اسم الصورة عندي :

ChatSearch_Figure3_Multimodal_Dialogue_Construction





Figure 4 — الأهم

لأنه Architecture النموذج ChatSearcher.

اسم الصورة عندي :

ChatSearch_Figure4_ChatSearcher_Architecture



النتائج :

Table 1: إحصائيات Dataset

	tChatSearch	iChatSearch	mChatSearch
Context modality	text	image-text	image-text
Sample number	5000	10000	10000
Context length	66.7	12.4	56.5
Task input	multi-round textual dialogue	single image and text instruction	multi-round multimodal dialogue
Task output	image candidates	image candidates	image candidates

Table 1: Statistics of ChatSearch test split.

Table 2: أهم جدول نتائج لأنه يثبت تفوق ChatSearcher

Method	tChatSearch			iChatSearch			mChatSearch			Avg.
	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	
random choice	0.02	0.1	0.2	0.01	0.05	0.1	0.01	0.05	0.1	0.07
CLIP-i [4]	-	-	-	9.65	20.96	28.05	9.65	20.96	28.05	19.55
CLIP-t [4]	15.84	34.46	45.10	14.15	30.60	39.56	12.69	27.19	35.80	28.38
CLIP-ti [4]	-	-	-	12.33	26.81	35.15	13.18	28.56	37.07	25.52
FROMAGe [21]	15.94	36.76	48.60	12.56	29.65	39.65	14.36	32.58	42.80	30.32
ChatSearcher	27.38	52.48	63.50	35.54	61.16	71.57	37.90	64.22	74.06	54.20

Table 2: General conversational image retrieval results on ChatSearch test split.

Figure 7- مهمة جداً

توضح مقارنة نوعية بين ChatSearcher و CLIP وتبين أن ChatSearcher أفضل فهم الحوار متعدد الوسائط

