

Vision + X: A Survey on Multimodal Learning in the Light (1 (of Data (2024

الرابط

<https://arxiv.org/abs/2406.05211>

ما المشكلة التي تناقشها الورقة؟

تخيلي إنساناً يرى صورة ويسمع صوتاً ويقرأ نصاً بنفس الوقت.

الذكاء الاصطناعي التقليدي يتعامل مع:

- نص فقط
- صورة فقط
- صوت فقط

أما **Multimodal Learning** فيتعامل مع كل هذه الوسائط معاً.

الورقة تحاول الإجابة عن:

كيف نجعل النموذج يفهم أكثر من نوع بيانات في نفس الوقت؟

ماذا قدمت؟

قسمت عالم **Multimodal Learning** إلى:

Text + Image

مثل:

- ChatGPT Vision
- CLIP

Text + Audio

مثل:

- المساعدات الصوتية

Text + Image + Audio

مثال:

- Gemini
- GPT-4V

أهم شيء بالنسبة لبحثنا

الورقة تقول:

أغلب الأبحاث تفترض أن جميع الوسائط موجودة ومتاحة دائماً.

لكن الواقع مختلف.

مثلاً:

- المستخدم يرسل صورة فقط
- أو صورة ونص بدون صوت
- أو صوت فقط

هنا تظهر مشكلة **Missing Modality**.

وهذه بداية الـ Gap الخاص فينا.

Deep Multimodal Learning with Missing Modality: A (2 (Survey (2024

الرابط

<https://arxiv.org/abs/2409.07825>

لماذا هذه الورقة مهمة جداً؟

لأنها تتحدث عن المشكلة الأقرب لفكرتنا.

ما هي **Missing Modality**؟

مثال:

النظام يتوقع:

- صورة
- نص
- صوت

لكن المستخدم أعطى:

- صورة
- نص

ولم يعطِ صوتاً.

إذن الصوت مفقود.

يسمى:

Missing Modality

ماذا فعل الباحثون؟

جمعوا أكثر من 300 بحث.

ثم صنفوها إلى حلول مختلفة.

الحل الأول

تعويض الوسيط المفقود

مثال:

إذا اختفى الصوت

يحاول النظام تخمينه من الصورة والنص.

الحل الثاني

تجاهل الوسيط المفقود

ويعمل بما هو موجود فقط.

الحل الثالث

إنشاء تمثيل مشترك

Shared Representation

بحيث لا يهم إذا اختفى أحد الوسائط.

أين الـ Gap؟

الورقة تركز على:

- Classification
- Recognition
- Prediction

لكن لا تركز كثيراً على:

Conversational Information Retrieval

أي الحوار المتعدد الجولات.

BalanceBenchmark: A Survey for Multimodal Imbalance (3 Learning) (2025)

الرابط

<https://arxiv.org/abs/2502.10816>

المشكلة التي تناقشها

هنا لدينا جميع الوسائط موجودة.

لكن يوجد مشكلة أخرى.

مثال

لدينا:

- صورة
- نص

الصورة غنية جداً بالمعلومات.

النص قصير جداً.

النموذج يبدأ بالاعتماد على الصورة فقط.

ويتجاهل النص.

هذه تسمى:

Modality Imbalance

ماذا قدمت الورقة؟

أنشأت Benchmark كامل.

أي منصة لاختبار:

- هل النموذج متوازن؟
- هل يعتمد على جميع الوسائط؟
- هل يهمل أحدها؟

لماذا مهمة لكم؟

لأن بحثكم يريد حل:

Missing Modality

•

Modality Imbalance

معاً

وهذا ما لا تعالجه معظم الأعمال الحالية.

**Diagnosing and Re-learning for Balanced Multimodal (4
(Learning (ECCV 2024**

الرابط

<https://arxiv.org/abs/2407.09705>

الفكرة ببساطة

الباحثون لاحظوا أن بعض الوسائط:

- تتعلم بسرعة
- وبعضها يتعلم ببطء

مثال

لدينا:

صورة + نص

- الصورة قوية.
- النص ضعيف.
- النموذج يعتمد على الصورة.

ماذا فعلوا؟

قاموا بقياس جودة تعلم كل وسيط.

إذا وجدوا وسيطاً ضعيفاً:

يعطونه فرصة إضافية للتعلم.

Re-learning

أي إعادة تعلم.

النتيجة

صار النموذج:

- أكثر توازناً
- يستفيد من جميع الوسائط
- لا يعتمد على وسيط واحد فقط

الورقة	ماذا تقدم؟	ماذا ينقصها؟
Vision + X	أساسيات Multimodal Learning	لا تعالج Missing Modality بعمق
Missing Modality Survey	حلول غياب الوسائط	لا تركز على Conversational Retrieval

لا تعالج الحوار	مشكلة عدم توازن الوسائط	Balance Benchmark
لا تعالج Missing Modality والحوار معاً	موازنة الوسائط	Diagnosing & Re-learning

اين الفجوة البحثية (Research Gap)؟

الفجوة ليست شيئاً موجوداً داخل الورقة كقسم مستقل دائماً.

نحن نكتشفها عندما نربط عدة أوراق مع بعضها.

مثلاً:

الورقة الأولى

تقول:

- توجد مشكلة عندما تكون بعض الوسائط غير متوفرة.

ورقة Missing Modality

تقول:

- توجد حلول لمعالجة غياب الوسائط.

ورقة Modality Imbalance

تقول:

- توجد مشكلة عندما يسيطر وسيط على بقية الوسائط.

عند البحث في Conversational Information Retrieval

نجد أن أغلب الأعمال تفترض:

- جميع الوسائط موجودة.
- جميع الوسائط متوازنة.

وهنا تظهر الفجوة.

كيف نكتب الـ Gap؟

مثال:

Existing multimodal conversational retrieval systems generally assume the availability of complete and balanced modalities.

However, real-world interactions frequently involve missing modalities and unequal modality contributions, which remain insufficiently explored in conversational retrieval settings.

(الأنظمة الحالية تفترض أن جميع الوسائط متوفرة ومتوازنة، بينما في الواقع العملي كثيراً ما تكون بعض الوسائط مفقودة أو أقوى من غيرها، وهذه المشكلة لم تُدرس بشكل كافٍ في أنظمة الاسترجاع الحوارية)

ما الذي سنبنيه نحن؟

بدلاً من أن يكون النظام:

Text + Image + Audio



Retrieval

نقترح:

Text + Image + Audio



Missing Modality Detector



Modality Importance Analyzer



Adaptive Fusion Module



Conversational Retrieval



Feedback Update

1. Missing Modality Detector

يفحص:

- هل يوجد نص؟
- هل توجد صورة؟
- هل يوجد صوت؟

مثال:

✓ النص

✓ الصورة

✗ الصوت

يعرف أن الصوت مفقود

2. Modality Importance Analyzer

يقيس أهمية كل وسيط

مثلاً:

Weight(Image)=0.7 :الصورة فيها معلومات كثيرة

Weight(Text)=0.3 :النص قصير

3. Adaptive Fusion Module

Text 50% Image 50% :بدلاً من إعطاء جميع الوسائط نفس الأهمية

Text 30% Image 70% أو العكس. :يجعل الأوزان ديناميكية

4. Conversational Retrieval

يقوم بعملية البحث أو الاسترجاع

مثلاً: المستخدم يقول

- ابحث عن هذا المنتج
- ويرسل صورة
- ثم يقول : أريده بلون أسود

النظام يتذكر الحوار السابق

5. Feedback Update

:بعد كل جولة حوار

- هل كانت الصورة مفيدة؟
- هل النص كان أوضح؟

فيعدل الأوزان تلقائياً.

ونلاحظ أن الجميع حلوا أجزاء من المشكلة، لكن لا أحد جمع

- Missing Modality
- Modality Imbalance
- Conversational Retrieval

في نظام واحد.

وهذا بالضبط ما يجعل الفكرة قابلة للنشر إذا أثبتتم بالتجارب أنها تحسن النتائج

إذا أردنا ورقة عالمية وقابلة للنشر فلا يكفي أن نقرأ **Surveys** فقط، بل نحتاج 3 أنواع من الأوراق:

1. **Surveys** → لفهم المجال.
2. **State-of-the-Art Papers** → لمعرفة أحدث الحلول.
3. **Papers** قريبة من فكرتنا جداً → لاستخراج الـ **Gap** الحقيقي

المجموعة الأولى: أوراق Conversational Retrieval (مهمة جداً)

(ChatSearch (2024 (1

العنوان:

ChatSearch: A Dataset and a Generative Retrieval Model for General Conversational Image Retrieval

الرابط:

<https://arxiv.org/abs/2410.18715>

لماذا مهمة؟

هذه أول ورقة قريبة جداً من فكرتنا

الفكرة:

- المستخدم يتحاور مع النظام عدة مرات.
- النظام يسترجع صوراً بناءً على الحوار الكامل.
- تعتمد على **Multi-turn Conversation**

ماذا ينقصها؟

- لا تعالج Missing Modality.
- لا تعالج Modality Imbalance.
- تفترض توفر البيانات المطلوبة.

Asking Multimodal Clarifying Questions in (2 (Mixed-Initiative Conversational Search (2024

الرابط:

<https://arxiv.org/abs/2402.07742>

الفكرة

إذا كان استعلام المستخدم غامضاً:

بدلاً من سؤال نصي فقط،

النظام يعرض صوراً للمساعدة في توضيح المقصود.

لماذا مهمة؟

لأنها تربط:

- Conversation
- Retrieval
- Multimodality

في ورقة واحدة.

Gap

لا يوجد Missing Modality.

المجموعة الثانية: أوراق Retrieval الحديثة

(3 (MM-Embed (2024

العنوان:

MM-Embed: Universal Multimodal Retrieval with Multimodal LLMs

الرابط:

<https://arxiv.org/abs/2411.02571>

ماذا تقدم؟

تبني Retriever متعدد الوسائط باستخدام MLLMs.

يدعم:

- Text → Image
- Image → Text
- Multimodal → Multimodal Retrieval

وحقق نتائج قوية جداً على عدة Benchmarks.

لماذا مهمة؟

قد يكون Baseline ممتازاً لكم.

Gap

- لا يعالج Missing Modality.
- ليس Conversational.

المجموعة الثالثة: Missing Modality

(Missing Modality Prediction for Unpaired Multimodal Learning (2024 (4

الرابط:

<https://arxiv.org/abs/2407.12616>

الفكرة

إذا اختفت صورة أو صوت:

النظام يتنبأ بالتمثيل الخاص بالوسيط المفقود داخل فضاء التمثيل Embedding Space.

لماذا مهمة؟

قد نستخدم نفس الفكرة داخل نظام Retrieval.

(MIT-FRNet (2024 (5

الرابط:

<https://www.sciencedirect.com/science/article/pii/S0957417424005219>

الفكرة

إعادة بناء **Features** الوسيط المفقود.

بدلاً من تجاهله.

Gap

- ليست **Retrieval**.
- ليست **Conversational**.

المجموعة الرابعة: Retrieval + Missing Modality

(CAR-MFL (2024 (6

الرابط:

<https://arxiv.org/abs/2407.08648>

لماذا أحب هذه الورقة؟

لأنها تستخدم:

Retrieval

لحل مشكلة

.Missing Modalities

هذه من أقرب الأوراق لفكرتنا.

